大模型参数高效微调及扩展

PEFT

Prompt类

- prompt tuning：在输入层加一个embedding层
- P-tuning：在输入层加一个embedding和一个LSTM或MLP
- prefix tuning：在每一层加入一个embedding和一个MLP
- P-tuning v2：在每一层都加一个embedding层

Adapter类

- Adapter Tuning：针对每一个Transformer层，增加了两个Adapter结构(分别是多头注意力的投影之后和第二个feed-forward层之后)
- Adapter Fusion：在 Adapter 的基础上进行优化，通过将学习过程分为两阶段来提升下游任务表现：包括知识提取和知识组合。
  - 知识提取阶段：在不同任务下引入各自的Adapter模块，用于学习特定任务的信息。
  - 知识组合阶段：将预训练模型参数与特定于任务的Adapter参数固定，引入新参数（AdapterFusion）来学习组合多个Adapter中的知识，以提高模型在目标任务中的表现
- Adapter Drop：在不影响任务性能的情况下，对Adapter动态高效的移除，尽可能的减少模型的参数量，提高模型在反向传播（训练）和正向传播（推理）时的效率

Lora类

- LoRA：用两个低秩矩阵替代待更新的权重矩阵的增量
  - 在原始预训练语言模型（PLM）旁边增加一个旁路，做一个降维再升维的操作，来模拟所谓的内在秩。训练的时候固定PLM的参数，只训练降维矩阵A与升维矩阵B。模型的输入输出维度不变，输出时将BA与PLM的参数叠加。随机高斯分布初始化A，用0矩阵初始化B，保证训练的开始此旁路矩阵依然是0矩阵。通过SVD分解来找到原权重矩阵的内在秩。α的作用等同于学习率。

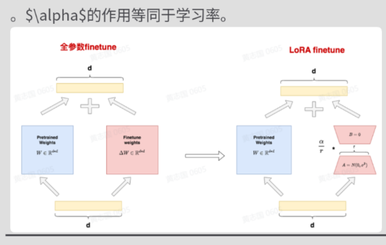

- QLoRA：三个优化点：1. 使用4 bit NormalFloat(NF4) 量化；2. 双量化，包含对普通参数的一次量化和对量化后的参数的再一次量化，可以进一步减小缓存占用；3. 引入了分页优化器，在显存不够时候，将保存的部分梯度转移到CPU上，以防止梯度检查点期间的内存峰值。
- AdaLoRA：用奇异值分解P\Gamma Q代替AB，根据loss梯度评估对角线上值进行重要性评分，根据评分动态分配参数预算给权重矩阵
  - 1. AdaLoRA将关键的增量矩阵分配高秩以捕捉更精细和任务特定的信息，而将较不重要的矩阵的秩降低，以防止过拟合并节省计算预算。2. 以奇异值分解的形式对增量更新进行参数化，并根据重要性指标裁剪掉不重要的奇异值，同时保留奇异向量。3. 在训练损失中添加了额外的惩罚项，以规范奇异矩阵P和Q的正交性，从而避免SVD的大量计算并稳定训练。

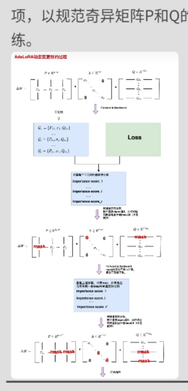

- ReLoRA ②：引入3个可学习的向量l_k,l_v,l_ff来对激活进行缩放，方式是直接进行element-wise乘法，还额外引入了两个损失项:unlikelihood loss和length-normalized loss，前者用于加重不正确输出的惩罚，后者对所有输出的长度归一化对数概率应用一个标准的softmax cross-entropy损失。

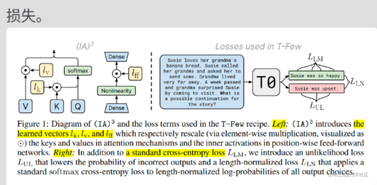

Figure 1: Diagram of (IA)³ and the loss terms used in the T-Few recipe. *Left:* (IA)³ introduces the learned vectors l_k, l_v, and l_{ff} which respectively rescale (via element-wise multiplication, visualized as ⊙) the keys and values in attention mechanisms and the inner activations in position-wise feed-forward networks. *Right:* In addition to a standard cross-entropy loss L_{LM}, we introduce an unlikelihood loss L_{UL} that lowers the probability of incorrect outputs and a length-normalized loss L_{LN} that applies a standard softmax cross-entropy loss to length-normalized log-probabilities of all output choices.

- IA3

其他

- BitFit：稀疏的微调方法，它训练时只更新bias的参数或者部分bias参数

混合式

- MAM Adapter：用 FFN 层的并行Adapter和soft prompt的组合

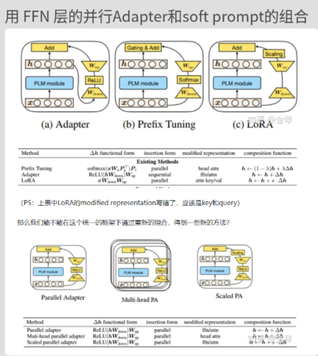

- UniPELT：使用三个线性层GP、GL、GA作为门控单元，其中GP参数控制Prefix-tuning方法的开关，GL控制LoRA方法的开关，GA控制Adapter方法的开关

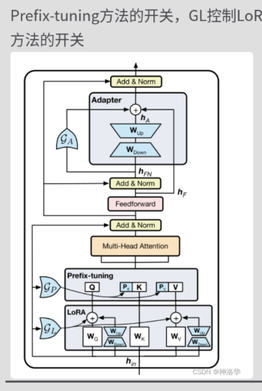

上下文扩展

position encoding改进

Interpolation

- Position Interpolation：注意力分数 |m-n| 增大而下降的上界可能太宽松，从而导致在训练长度外注意力分数出现较大的波动，进而降低外推效果。

$$f'(\mathbf{q}_m, m) = f(\mathbf{q}_m, \frac{m}{\lambda}) \tag{10}$$

其中，$\lambda = \frac{L'}{L} > 1$。直观上，相当于将整段位置 m 缩小至 $\frac{m}{\lambda}$。

将位置缩放的结果代入到等式(9)中，则m和n的注意力分数 $a(m,n)$ 为

$$a(m,n) = \mathrm{Re}[\sum_j^{d/2} h_j e^{i\frac{n}{\lambda}\theta_j}] \tag{11}$$

Extrapolation

- 静态NTK感知缩放RoPE：基于NTK的视角认为，标准MLP神经网络并不能很好的学习高频的信号。将这个结论应用到RoPE中，也就意味着：**当 j 较小时，模型可能对插值的位置并没有很好的泛化能力**。因此，当 j 较小时使用外推，随着 j 的增大逐步开始插值。也就是所谓的高频外推、低频内插。

在具体介绍NTK-RoPE前，先将等式(11)中 λ 放置在 θ_j 下，即

$$a(m,n) = \mathrm{Re}[\sum_j^{d/2} h_j e^{i\theta\frac{n}{L}}] \tag{12}$$

由于 $\theta_j = 10000^{-\frac{2j}{d}}$，则 $\frac{\theta_j}{\lambda} = (10000\lambda)^{-\frac{2j}{d}}$，相当于放大了原始base(10000)。

相比于等式(12)的位置插值，NTK-RoPE放大base的方式为

$$\theta_j = (10000\lambda^{\frac{d}{d-2}})^{-\frac{2j}{d}} = 10000^{-\frac{2j}{d}} \cdot \lambda^{-\frac{2j}{d-2}} \tag{13}$$

当 j 比较小的时候，$\lambda^{-\frac{2j}{d-2}}$ 接近于1，则 θ_j 接近原始的 θ_j；而当 j 较大时，$\lambda^{-\frac{2j}{d-2}}$ 接近于 $\frac{1}{\lambda}$，θ_j 接近于位置插值的 θ_j。通过这样的方式就实现了高频外推、低频内插的效果。

- 动态NTK缩放RoPE：在静态NTK中，推理长度 L' 是一个固定的值。但是，对于自回归语言模型来说，每次推理的序列长度都会增加。因此推理长度 L' 并不是固定的值。若使用\lambda=L'/L，当推理长度小于L时，性能会有折扣；当推理长度大于 L'，模型效果可能会突然退化。解决办法是：在每次前向传播时，动态NTK使用的缩放因子为\lambda=max(1,l'/L)，其中 l' 是当前序列的长度。这样就能动态的适应自回归模型。
- consistent of Dynamically Scaled RoPE：

To put it clearly, while LLM decoding, the current DynamicNTKRope is implemented as

$$KQ^T = [\mathrm{rotate}(\mathrm{key}_0, \alpha_{seq1}), \mathrm{rotate}(\mathrm{key}_1, \alpha_{seq1}), \mathrm{rotate}(\mathrm{key}_2, \alpha_{seq1})] * \mathrm{rotate}(\mathrm{query}, \alpha_{seq1})$$

From my understanding, we should keep the rotation base consistent, which is:

When decoding `sequence length = seq1`

$$KQ^T = [\mathrm{rotate}(\mathrm{key}_0, \alpha_{seq1}), \mathrm{rotate}(\mathrm{key}_1, \alpha_{seq1})] * \mathrm{rotate}(\mathrm{query}, \alpha_{seq1})$$

As decoding sequence length increases to `seq2`,

$$KQ^T = [\mathrm{rotate}(\mathrm{key}_0, \alpha_{seq3}), \mathrm{rotate}(\mathrm{key}_1, \alpha_{seq3}), \mathrm{rotate}(\mathrm{key}_2, \alpha_{seq3}),] * \mathrm{rotate}(\mathrm{query}, \alpha_{seq3})$$

混合

- Rectified/Leakey Rectified RoPE：一种结合外推和内插的方法，即通过设定一个窗口w，在窗口内使用大小为1的位置间隔，在窗口外我们使用大小为1/k的位置间隔,只要w小于训练长度，那么通过控制k，我们就可以在精确保持了局域性的前提下，使得所有位置编码不超过训练长度，简单直接地结合了直接外推和位置内插。此外，当k->\infinity,不管输入长度是多少，它的位置编码范围都不超过w，所以这是一种有可能支持任意长度的Context的方案。k取有限值时称为Leaky ReRoPE, 无限值是称为ReRoPE。

$$\begin{pmatrix}
0 & & & & & & & & & & & \\
1 & 0 & & & & & & & & & & \\
2 & 1 & 0 & & & & & & & & & \\
\ddots & 2 & 1 & 0 & & & & & & & & \\
w-1 & \ddots & 2 & 1 & 0 & & & & & & & \\
w & w-1 & \ddots & 2 & 1 & 0 & & & & & & \\
w+\frac{1}{k} & w & \ddots & \ddots & 2 & 1 & 0 & & & & & \\
w+\frac{2}{k} & w+\frac{1}{k} & \ddots & \ddots & \ddots & 2 & 1 & 0 & & & & \\
\ddots & w+\frac{2}{k} & \ddots & \ddots & \ddots & \ddots & 2 & 1 & 0 & & & \\
\ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & \ddots & & \\
\ddots & \ddots & \ddots & w+\frac{2}{k} & w+\frac{1}{k} & w & w-1 & \ddots & 2 & 1 & 0 & \\
w+\frac{k+w}{k} & \ddots & \ddots & \ddots & w+\frac{2}{k} & w+\frac{1}{k} & w & w-1 & \ddots & 2 & 1 & 0
\end{pmatrix} \tag{3}$$

ROPE基本原理

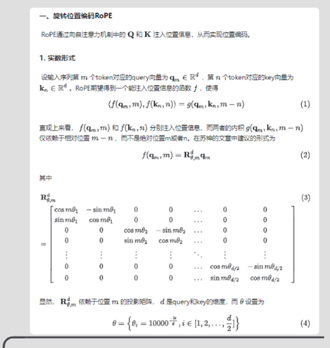

一、旋转位置编码RoPE

RoPE通过向自注意力机制中的 $\mathbf{Q}$ 和 $\mathbf{K}$ 注入位置信息，从而实现位置编码。

1. 实数形式

设输入序列第 m 个token对应的query向量为 $\mathbf{q}_m \in \mathbb{R}^d$，第 n 个token对应的key向量为 $\mathbf{k}_n \in \mathbb{R}^d$，RoPE期望得到一个能注入位置信息的函数 f，使得

$$\langle f(\mathbf{q}_m, m), f(\mathbf{k}_n, n)\rangle = g(\mathbf{q}_m, \mathbf{k}_n, m-n) \tag{1}$$

直观上来看，$f(\mathbf{q}_m, m)$ 和 $f(\mathbf{k}_n, n)$ 分别注入位置信息，两两点的内积 $g(\mathbf{q}_m, \mathbf{k}_n, m-n)$ 仅依赖于相对位置 $m-n$，而不是绝对位置m和n。在苏神的文章中建议的形式为

$$f(\mathbf{q}_m, m) = \mathbf{R}_{d,m}^d \mathbf{q}_m \tag{2}$$

其中

$$\mathbf{R}_{d,m}^d = \begin{bmatrix} \cos m\theta_1 & -\sin m\theta_1 & 0 & 0 & \dots & 0 & 0 \\ \sin m\theta_1 & \cos m\theta_1 & 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & \cos m\theta_2 & -\sin m\theta_2 & \dots & 0 & 0 \\ 0 & 0 & \sin m\theta_2 & \cos m\theta_2 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & \cos m\theta_{d/2} & -\sin m\theta_{d/2} \\ 0 & 0 & 0 & 0 & \dots & \sin m\theta_{d/2} & \cos m\theta_{d/2} \end{bmatrix} \tag{3}$$

显然，$\mathbf{R}_{d,m}^d$ 依赖于位置 m 的投影矩阵，d 是query和key的维度，而 θ 设置为

$$\theta = \left\{\theta_i = 10000^{-\frac{2}{d}}, i \in [1, 2, \dots, \frac{d}{2}]\right\} \tag{4}$$

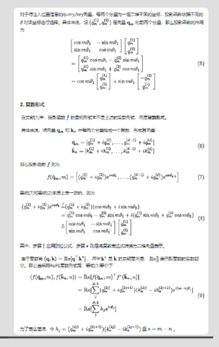

为了简化起见，令 $\theta_i = (\xi_{2i}^{(k)} + i\xi_{2i+1}^{(k)})(\xi_{2i}^{(q)} - i\xi_{2i+1}^{(q)})$ 且 $s = m - n$，

- ALiBi不向单词embedding中添加位置embedding，而是根据token之间的距离给 attention score 加上一个预设好的偏置矩阵。比如 相对位置差 1 就加上一个 -1 的偏置，两个 token 距离越远这个负数就越大，代表他们的相互贡献越低。由于注意力机制一般会有多个head，这里针对每一个head会乘上一个预设好的斜率项(Slope)。$m=2^{-8/n}$

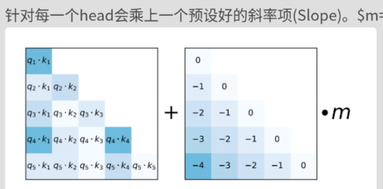

Alibi

注意力改进

window attention

- sliding window attention with re-computation
- shift short attention：设初始上下文长度为l,把微调时的长上下文分成若干组，每组长度等于l，在执行self-attention中，按组进行窗口移动

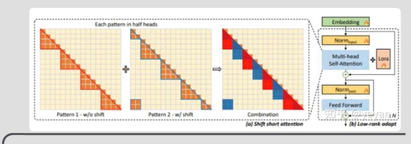

- streaming-LLM：window attention+保留初始token

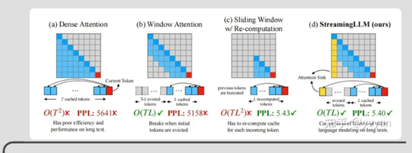

log（n）注意力缩放

- 在注意力计算公式中，QK^T上加入一个$log_m n$,其中m是训练时的长度，n为预测时的长度

其他

- Naive Bayes-based Context Extension：只需要修改一下解码函数中的logits构建方式，即插即用、模型无关、无须微调、线性效率、实现简单，NBCE的一大缺点是无序性，即无法识别Context的输入顺序，这在续写故事等场景可能表现欠佳

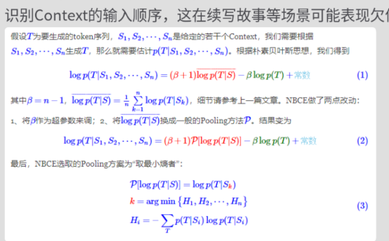

假设T为要生成的token序列，$S_1, S_2, \cdots, S_n$是给定的若干个Context，我们需要根据$S_1, S_2, \cdots, S_n$生成T，那么就需要估计$p(T|S_1, S_2, \cdots, S_n)$，根据朴素贝叶斯思想，我们得到

$$\log p(T|S_1, S_2, \cdots, S_n) = (\beta+1)\overline{\log p(T|S)} - \beta \log p(T) + \text{常数} \tag{1}$$

其中$\beta = n-1$，$\overline{\log p(T|S)} = \frac{1}{n}\sum_{k=1}^{n} \log p(T|S_k)$，细节请参考上一篇文章。NBCE做了两点改动：

1、将β作为超参数来调；2、将$\overline{\log p(T|S)}$换成一般的Pooling方法$\mathcal{P}$，结果变为

$$\log p(T|S_1, S_2, \cdots, S_n) = (\beta+1)\mathcal{P}[\log p(T|S)] - \beta \log p(T) + \text{常数} \tag{2}$$

最后，NBCE选取的Pooling方案为"取最小熵者"：

$$\begin{aligned} \mathcal{P}[\log p(T|S)] &= \log p(T|S_k) \\ k &= \arg\min\{H_1, H_2, \cdots, H_n\} \\ H_i &= -\sum_T p(T|S_i)\log p(T|S_i) \end{aligned} \tag{3}$$